

Analiza wpływu zastosowania wybranych  
technik przygotowania danych do analizy, na  
jakość analizy danych

Dariusz Litwiński

19 sierpnia 2023



# Spis treści

<b>1</b>	<b>Problem Analizy Danych</b>	<b>5</b>
1.1	Analiza Danych . . . . .	5
1.1.1	Pozyskiwanie: gromadzenie danych . . . . .	5
1.1.2	Przygotowanie: przetwarzanie danych . . . . .	5
1.1.3	Analiza: modelowanie danych . . . . .	6
1.1.4	Działanie: podejmowanie decyzji . . . . .	6
1.2	Jakość Danych . . . . .	6
1.3	Problemy z Danymi . . . . .	7
1.3.1	Brakujące wartości . . . . .	7
1.3.2	Wartości odstające . . . . .	7
1.3.3	Kolumny kategoryczne . . . . .	8
1.4	Cel pracy . . . . .	8
<b>2</b>	<b>Metody Przygotowania Danych</b>	<b>9</b>
2.1	Uzupełnianie brakujących wartości . . . . .	9
2.2	Wykrywanie wartości odstających . . . . .	9
2.3	Kodowanie wartości kategorycznych . . . . .	9
2.4	Standaryzacja . . . . .	10
<b>3</b>	<b>Środowisko wykonawcze</b>	<b>11</b>
3.1	Specyfikacja sprzętowa, system i środowisko . . . . .	11
3.2	Zbiory danych . . . . .	11
3.2.1	League of Legends stats . . . . .	12
3.2.2	Australian Rain Forecast . . . . .	12
3.2.3	Titanic Survival . . . . .	12
3.3	Przygotowanie danych do eksperymentów . . . . .	12
3.3.1	Część wspólna dla wszystkich zbiorów danych . . . . .	12
3.3.2	Zbiór danych Titanic . . . . .	12
3.3.3	Zbiór danych Lol Stats . . . . .	13
3.3.4	Zbiór danych Australian Rain Forecast . . . . .	13
<b>4</b>	<b>Wykonane Eksperymenty</b>	<b>15</b>
4.1	Użyte klasyfikatory . . . . .	15
4.1.1	xgBoost . . . . .	15

4.1.2	Las Losowy . . . . .	15
4.1.3	k-Najbliższych Sąsiadów . . . . .	15
4.2	Brak Preprocessingu . . . . .	16
4.3	Wypełnienie brakujących wartości średnią . . . . .	16
4.4	Wypełnienie brakujących wartości minimum . . . . .	16
4.5	Wypełnienie brakujących wartości maksimum . . . . .	17
4.6	Wypełnienie brakujących wartości za pomocą regresji liniowej . . . . .	17
4.7	Standaryzacja . . . . .	17
4.8	Standaryzacja oraz skalowanie do przedziału (0,1) . . . . .	18
4.9	Skalowanie do przedziału (0,1) oraz usunięcie wartości odstających . . . . .	18
4.10	Kodowanie wartości kategoriycznych . . . . .	19
4.11	Kodowanie wartości kategoriycznych oraz wypełnienie brakujących wartości średnią . . . . .	19
4.12	Scenariusz indywidualnego podejścia do zbioru danych . . . . .	19
4.12.1	League of Legends stats . . . . .	19
4.12.2	Australian Rain Forecast . . . . .	20
4.12.3	Titanic Survival . . . . .	21
<b>5</b>	<b>Wyniki Eksperymentów</b>	<b>23</b>
5.1	League of Legends stats . . . . .	24
5.1.1	Wypełnienie brakujących wartości . . . . .	24
5.1.2	Standaryzacja . . . . .	26
5.1.3	Kodowanie . . . . .	28
5.1.4	Indywidualne podejście . . . . .	31
5.2	Australian Rain Forecast . . . . .	32
5.2.1	Wypełnienie brakujących wartości . . . . .	32
5.2.2	Standaryzacja . . . . .	34
5.2.3	Kodowanie . . . . .	36
5.2.4	Indywidualne podejście . . . . .	39
5.3	Titanic Survival . . . . .	40
5.3.1	Wypełnienie brakujących wartości . . . . .	40
5.3.2	Standaryzacja . . . . .	42
5.3.3	Kodowanie . . . . .	44
5.3.4	Indywidualne podejście . . . . .	46
5.4	Średnie wyniki . . . . .	48
5.4.1	Wypełnienie brakujących wartości . . . . .	48
5.4.2	Standaryzacja . . . . .	51
5.4.3	Kodowanie . . . . .	54
5.4.4	Indywidualne podejście . . . . .	57
<b>6</b>	<b>Podsumowanie</b>	<b>61</b>
6.1	Konieczność przygotowania danych . . . . .	61
6.2	Wpływ źle dobranych sposobów przygotowania danych . . . . .	62
6.3	Najlepsze wyniki po przygotowaniu danych . . . . .	63
6.4	Potencjalne dalsze kierunki badań . . . . .	65
6.5	Najlepsze praktyki przygotowania danych . . . . .	66

# Rozdział 1

## Problem Analizy Danych

### 1.1 Analiza Danych

Analiza danych to proces, w którym przekształcamy surowe dane w wiedzę i wnioski, dzięki którym jesteśmy w stanie podejmować lepsze decyzje [4]. Wewnątrz tego procesu można wyróżnić następujące fazy:

#### 1.1.1 Pozyskiwanie: gromadzenie danych

Zanim analiza danych będzie możliwa należy pozyskać dane, jest to istotna część procesu, ponieważ to od niej zależy to, jak trafne wnioski będziemy mogli wysnuć na późniejszych etapach. Bardzo ważne jest to, jak dużą ilość danych uda nam się zebrać, a także jak dokładne one będą. Możemy pozyskiwać dane z różnorodnych źródeł, na przykład:

- Zapisywać wartości zbierane przez czujniki [5]
- Korzystać z ankiet zebranych wśród danej populacji [7]
- Zbierać dane o zachowaniach użytkowników w trakcie korzystania ze strony internetowej [8]
- Wykorzystywać dane statystyczne/historyczne [6]

Jesteśmy w tej kwestii ograniczeni jedynie przez dziedzinę, w jakiej przeprowadzamy analizę danych. Istotną kwestią jest również to, w jakim formacie są przechowywane dane. Może okazać się, że pierwszym etapem przetwarzania danych będzie odpowiednie ich sformatowanie, bądź nawet ich cyfryzacja, jeśli były by przechowywane w formie fizycznej, na przykład jako papierowe archiwa

#### 1.1.2 Przygotowanie: przetwarzanie danych

Aby móc w pełni korzystać ze zgromadzonych danych, należy je przygotować, odpowiednio sformatować. Poza przygotowaniem odpowiedniego formatu da-

nych, możemy wyróżnić następujące sposoby na przygotowanie danych do analizy:

- Wypełnienie brakujących wartości
- Standaryzacja danych liczbowych
- Kodowanie wartości kategorycznych jako liczbowe

Dzięki wykorzystaniu powyższych sposobów możemy znacznie zwiększyć jakość analizy danych, a co za tym idzie wnioski do których dojdziemy w trakcie procesu będą trafniejsze i przyniosą lepsze rezultaty

### 1.1.3 Analiza: modelowanie danych

Mając do dyspozycji przygotowane dane możemy przejść do ich właściwej analizy, na podstawie której tworzymy modele, klasyfikatory [15], systemy rekomendacji [16], dokonujemy klasteryzacji [17]. Najczęściej nie tworzymy ich od zera, a wspomagamy się dostępnymi bibliotekami, które zawierają najpopularniejsze algorytmy. Zdarza się, że nie jesteśmy zadowoleni z wyników, jakie przynosi wykorzystanie stworzonych modeli, bądź chcielibyśmy dokonać dalszej optymalizacji czasowej, w takim przypadku możemy rozważyć dodatkowe przygotowanie danych, aby uzyskać pożądany efekt. Po dobrze przeprowadzonej analizie, jesteśmy w stanie wykorzystać stworzone na tym etapie narzędzia do rozwiązywania rzeczywistych problemów.

### 1.1.4 Działanie: podejmowanie decyzji

Mając gotowe narzędzia będące wynikiem modelowania danych, możemy je wykorzystać aby podjąć konkretne decyzje w prawdziwym świecie: Wykorzystać stworzony klasyfikator w diagnostyce chorób, wdrożyć system rekomendacji na naszej stronie internetowej, wykorzystać stworzone klastry danych do kategoryzacji klientów. Każdy z przedstawionych problemów wymaga eksperckiej wiedzy oraz ogromnego doświadczenia, a dzięki analizie danych możemy znacznie usprawnić ich rozwiązywanie.

## 1.2 Jakość Danych

Jakość danych jest oceniana na podstawie wielu kryteriów, zależnych od źródła informacji[24]:

- Kompletność - ilość danych która jest kompletna bądź zdatna do użycia. Jeśli duża część danych jest niekompletna, może to prowadzić do stronniczej bądź nawet omylnej analizy.
- Unikalność - jaka część z zestawu danych się powtarza, dla przykładu zestaw danych zawierających dane o klientach powinien każdemu z nich przypisać unikalny numer identyfikacyjny

- **Ważność** - To kryterium mówi o tym czy zebrane dane są w odpowiednim formacie
- **Aktualność** - W zależności od dziedziny którą się zajmujemy, dane mogą tracić na aktualności wraz z upływem czasu, przez na przykład postęp w danej dziedzinie bądź zmieniające się warunki
- **Dokładność** - poprawność danych w oparciu o ustalone "źródło prawdy". Jako, że może istnieć wiele źródeł tych samych danych, należy ustalić nadrzędne źródło danych, pozostałe zaś mogą potwierdzać dokładność tego pierwszego.
- **Stażność** - kryterium służące do porównywania danych z dwóch zestawów danych. Używanie różnych źródeł do szukania stałych trendów w danych. Dzięki temu wnioski pojawiające się w trakcie analizy mogą być traktowane z większym zaufaniem, jako że tworzone są na podstawie wielu niezależnych zestawów danych.
- **Dopasowanie do celu** - to kryterium pozwala nam zapewnić fakt, że dane które są zbierane posłużą nam do rozwiązania problemu, jaki przed nami stoi

## 1.3 Problemy z Danymi

Bardzo często zebrane dane nie nadają się bezpośrednio do pracy z nimi. Należy najpierw wykonać szereg operacji aby pozbyć się następujących problemów:

### 1.3.1 Brakujące wartości

W danych mogą występować brakujące wartości, na przykład czujniki mogą różnić się między sobą ilością pobieranych parametrów, ankietowani mogą pominąć niektóre pytania bez odpowiedzi. Brakujące wartości stanowią poważny problem, ponieważ model nie potrafi ich jednoznacznie zinterpretować, dlatego w trakcie przygotowania danych musimy podjąć decyzję, czy usunąć rekordy z brakującymi wartościami, przez co możemy znacznie zmniejszyć liczebność zbioru danych. Alternatywnym podejściem jest wypełnienie brakujących wartości. W miejsce braku może być wstawiona średnia, minimum, maksimum, lub też inna arbitralnie wybrana wartość. Pozornie wartości wstawiane w puste miejsca są kompletnie arbitralne, jednak bardzo często takie podejście skutkuje najlepszymi rezultatami, pod warunkiem że dobierzemy odpowiednią wartość do wstawiania. [9]

### 1.3.2 Wartości odstające

W niektórych przypadkach w danych mogą pojawić się takie wartości, które wyraźnie odstają od reszty i nie wnoszą sobą zbyt wiele informacji w kontekście analizy danych. Co więcej, mogą one zaciemniać pozostałą część danych,

maskując trendy bądź prowadząc do błędnych wniosków. Dlatego najlepszym podejściem jest wykrywanie oraz usuwanie wartości, które możemy uznać za odstające. Istnieją algorytmy pozwalające nam na odrzucenie wartości odstających. [12]

### 1.3.3 Kolumny kategoryczne

Wiele z modeli może pracować jedynie na wartościach liczbowych, podczas kiedy w zbiorach danych możemy znaleźć nie tylko takie wartości, ale również kategoryczne. Rezygnując z analizy tych danych tracilibyśmy wiedzę, jaką można z nich pozyskać. Nie jest to jednak konieczne, gdyż istnieją sposoby, aby zamienić te dane na postać liczbową za pomocą kodowania [14]

## 1.4 Cel pracy

Celem pracy jest sprawdzenie, jak poszczególne metody przygotowania danych wpływają na jakość analizy danych, konkretnie modelowania klasyfikatorów. Przeprowadzono eksperymenty z użyciem wielu metod przygotowania danych, a następnie porównano trafność klasyfikacji względem klasyfikatora bez przygotowania danych. Za brak przygotowania danych uznaje się usunięcie wszystkich rekordów z brakującymi wartościami oraz wszystkich kolumn nieliczbowych. Rozpoczynając prace postawiono hipotezę, że najlepszym sposobem na przygotowanie danych jest dogłębne ich zrozumienie, a następnie dostosowanie do nich użytych metod, jak i również fakt, że jakiegoliwek przygotowanie danych powinno wpłynąć pozytywnie na jakość analizy danych.



## Rozdział 2

# Metody Przygotowania Danych

Istnieje kilka najczęściej używanych metod przygotowania danych, które dzielą się na następujące grupy:

### 2.1 Uzupełnianie brakujących wartości

Najczęściej brakujące wartości w zbiorach danych uzupełnia się średnią lub najczęściej występującą wartością, jednak może zdarzyć się tak, że najlepszym rozwiązaniem jest uzupełnienie braków minimum, maksimum, zerem bądź inną arbitralnie wybraną wartością

### 2.2 Wykrywanie wartości odstających

Do wykrywania wartości odstających możemy wykorzystać manualne metody, ale również i algorytmy, które wykryją te wartości za nas. Do manualnych metod możemy zaliczyć: Wykrywanie za pomocą rozkładu normalnego, Z-score, IQR, wykrywanie za pomocą percentyli. Natomiast spośród automatycznych metod mamy do dyspozycji między innymi Las Izolacji lub Local Outlier Factor

### 2.3 Kodowanie wartości kategorycznych

Jeżeli znamy zależności między klasami i możemy je uporządkować, wtedy jesteśmy w stanie dokonać kodowania ręcznie, na przykład najmniejszą wartość dla edukacji podstawowej, a najwyższą dla edukacji wyższej. Natomiast jeżeli nie znamy tych zależności, możemy wykorzystać LabelEncoder, jednak on ponumeruje klasy w kolejności alfabetycznej, co nie zawsze jest pożądanym rezultatem. Innym podejściem jest One-Hot Encoding[11], który dla każdej z klas tworzy osobną kolumnę z wartością logiczną opisującą, czy dany rekord należy do tej

klasy. Powoduje to wygenerowanie sporej ilości kolumn, jednak mamy wtedy pewność, że nie stworzymy nowych zależności między klasami

## 2.4 Standaryzacja

Standaryzacja jest procesem, po zakończeniu którego zmienna ma średnią wartość oczekiwaną zero oraz odchylenie standardowe równe jeden, dzięki czemu zyskujemy większą przejrzystość w jej analizie. Bardziej wyraźne są skupienia wokół konkretnych wartości, jednak należy zadbać o to, aby przed standaryzacją pozbyć się wartości odstających, gdyż będą one miały negatywny wpływ na zmienną po standaryzacji

## Rozdział 3

# Środowisko wykonawcze

W poniższym rozdziale przedstawione zostało środowisko wykonawcze, w jakim przeprowadzono eksperymenty, a także opisano zbiory danych, na których je przeprowadzono

### 3.1 Specyfikacja sprzętowa, system i środowisko

Sprzęt: Laptop wyposażony w procesor Intel Core i5-1135G7 (2.4Ghz) ze zintegrowaną grafiką oraz 16GB pamięci RAM System operacyjny: Windows 10 Education Menadżer środowisk: Anaconda Navigator Python: 3.9.12 Edytor kodu: Visual Studio Code z dodatkami do edycji plików w formacie Jupyter notebook

### 3.2 Zbiory danych

Zbiory na których będziemy sprawdzać wpływ przygotowania danych są zbiorami do klasyfikacji. Do eksperymentów wybrano następujące zestawy danych:

Zbiory danych			
Nazwa zbioru	Ilość rekordów	Kolumny numeryczne	Kolumny kategoryczne
League of Legends Stats: S13[2]	485	3	7
Rain in Australia[3]	16443	16	7
Titanic[1]	891	5	5

Tablica 3.1: Podstawowe informacje na temat zbiorów danych

### 3.2.1 League of Legends stats

Zbiór zawierający statystyki postaci z gry League of Legends z dwóch wersji obecnego sezonu (13.1 oraz 13.3)

### 3.2.2 Australian Rain Forecast

Zbiór zawiera codzienne obserwacje dotyczące pogody z różnych lokalizacji na terenie Australii

### 3.2.3 Titanic Survival

Jest to zestaw informacji na temat pasażerów Titanica oraz tego, czy udało im się przeżyć, na podstawie czego budujemy model, który próbuje przewidzieć na podstawie informacji które mu przekazemy, czy dana osoba przeżyła katastrofę

## 3.3 Przygotowanie danych do eksperymentów

### 3.3.1 Część wspólna dla wszystkich zbiorów danych

Do przygotowania danych do eksperymentów służyła funkcja `prepare_to_file` (Przykład 3.1), która losowo generowała braki w danych, a następnie zapisywała nowopowstały niepełny zbiór danych do pliku.

```
def prepare_to_file(df, work_columns, filename, count):
    path=r'C:\Users\Darek\Documents\Magisterka
    \PracaMagPreprocessing\Datasets\Prepared'
    for i in range(count):
        df_copy = df.copy()
        df_random_rows = df.sample(frac=0.1)
        random_indexes = df_random_rows.index.tolist()
        for j in random_indexes:
            chosen_column = random.choice(work_columns)
            df_copy.at[j, chosen_column] = pd.NA
        df_copy.to_csv(path + '\\'+ filename +
            '_' +str(i+1)+'.csv', index=False)
```

Przykład 3.1: Funkcja generująca braki w podanym zbiorze danych

### 3.3.2 Zbiór danych Titanic

Dla zestawu danych Titanic wypełniono brakujące wartości dla wieku oraz portu, w którym pasażer wsiadł na statek (Przykład 3.2)

```
titanic['Age'] = titanic['Age']
.fillna(titanic['Age'].mean())
titanic['Embarked'] = titanic['Embarked']
```

```
.fillna('S')
```

Przykład 3.2: Przygotowanie zbioru danych Titanic do eksperymentów

### 3.3.3 Zbiór danych Lol Stats

Połączono dostępne zbiory danych dla wersji 13.1 oraz 13.3, dodano odpowiednią klasę dla bohatera K'Sante, dokonano odpowiedniego kodowania atrybutu klasyfikującego, a także sformatowano kolumny zawierające wartości procentowe

```
lol_stats = pd.concat([lol_13_1, lol_13_3])
for i in lol_stats.loc[lol_stats['Name'] == "K'Sante"].index.values:
    lol_stats.at[i, "Class"] = "Tank"
dict = {"God" : '0',
        "S" : '1',
        "A" : '2',
        "B" : '3',
        "C" : '4',
        "D" : '5'}
lol_stats = lol_stats.replace({"Tier": dict})
percent_columns = ['Win_%', 'Role_%',
                  'Pick_%', 'Ban_%']
for col in percent_columns:
    lol_stats[col] = lol_stats[col].str.rstrip('%')
```

Przykład 3.3: Przygotowanie zbioru danych Lol Stats do eksperymentów

### 3.3.4 Zbiór danych Australian Rain Forecast

Z całego dostępnego zbioru danych wybrano jedynie dane dotyczące stacji pogodowych z Sydney, Lotniska Sydney, Melbourne, Lotniska Melbourne, Canberra, Newcastle oraz Perth, a także zakodowano odpowiednio wartości binarne

```
aus_weather = aus_weather.dropna()
aus_weather = aus_weather[aus_weather['Location'].isin(
    ['Sydney', 'SydneyAirport',
     'Canberra', 'MelbourneAirport',
     'Melbourne', 'Brisbane', 'Perth'])]
aus_weather['RainToday'] = aus_weather['RainToday']
    .replace('Yes', '1')
aus_weather['RainToday'] = aus_weather['RainToday']
    .replace('No', '0')
aus_weather['RainTomorrow'] = aus_weather['RainTomorrow']
    .replace('Yes', '1')
aus_weather['RainTomorrow'] = aus_weather['RainTomorrow']
```

```
.replace('No', '0')
```

Przykład 3.4: Przygotowanie zbioru danych Australian Rain Forecast do eksperymentów

## Rozdział 4

# Wykonane Eksperymenty

Dla każdego z wybranych zbiorów danych przeprowadzono przygotowanie danych według ustalonego scenariusza, a także dodatkowego scenariusza w którym głównym celem było indywidualne podejście do zbioru oraz wyciągnięcie możliwie jak najwięcej informacji z dostępnych danych

### 4.1 Użyte klasyfikatory

#### 4.1.1 xgBoost

xgBoost to zoptymalizowana, zbiorowa biblioteka wzmacniająca gradient, zaprojektowana aby być wysoce efektywną, elastyczną oraz współpracującą z wieloma rodzajami sprzętu. XGBoost korzysta z równoległego wzmacniania drzew, dzięki którym rozwiązuje wiele problemów z dziedziny data science w szybki i dokładny sposób. [21]

#### 4.1.2 Las Losowy

Wykorzystano RandomForestClassifier z biblioteki scikitlearn. Jest to algorytm uczenia maszynowego metodą zespołową, która polega na tworzeniu wielu drzew decyzyjnych podczas uczenia modelu. Przy przypisywaniu obiektu do danej klasy wybierana jest ta, którą wybrała największa ilość drzew. Las losowy eliminuje tendencje drzew decyzyjnych do nadmiernego dopasowywania się do zbioru uczącego. [23]

#### 4.1.3 k-Najbliższych Sąsiadów

Wykorzystano KNeighborsClassifier z biblioteki scikitlearn. Danymi wejściowymi jest k najbliższych sąsiadów w zbiorze danych. Wyjściem jest przynależność do klasy danego obiektu. Obiekt jest klasyfikowany przez głosowanie większościowe spośród k-najbliższych ze zbioru uczącego. Zazwyczaj metryką

używaną do głosowania jest odległość euklidesowa, jednak nie jest to jedyna możliwość. [22]

## 4.2 Brak Preprocessingu

Pierwszy scenariusz, który w przyszłości będzie punktem odniesienia polegał na usunięciu rekordów, w których występowały jakiegokolwiek brakujące wartości

```
def no_preprocessing(df,num):
    df_1 = df.copy()
    df_1 = remove_missing(df_1)
    y = df_1['Survived']
    df_1= drop_columns(df_1,categorical)
    df_1 = df_1.apply(pd.to_numeric)
    X = df_1
    X_train, X_test, y_train, y_test = train_test_split(
        X, y, test_size=0.1, random_state=42)
    score("Titanic",
        num,
        "No_Preprocessing",
        X_train,y_train,X_test,y_test)
```

Przykład 4.1: Brak przygotowania danych dla zbioru danych Titanic

## 4.3 Wypełnienie brakujących wartości średnią

Drugi scenariusz zakładał wypełnienie brakujących wartości średnią za pomocą metod biblioteki pandas fillna() oraz mean()

```
def fill_missing_mean(df, work_columns):
    for col in work_columns:
        df[col] = df[col].fillna(df[col].mean())
    return df
```

Przykład 4.2: Wypełnienie brakujących wartości średnią

## 4.4 Wypełnienie brakujących wartości minimum

Kolejny scenariusz zakładał wypełnienie brakujących wartości średnią za pomocą metod biblioteki pandas fillna() oraz min()

```
def fill_missing_max(df, work_columns):
    for col in work_columns:
        df[col] = df[col].fillna(df[col].min())
    return df
```

Przykład 4.3: Wypełnienie brakujących wartości minimum



## 4.5 Wypełnienie brakujących wartości maksimum

Czwarty scenariusz zakładał wypełnienie brakujących wartości średnią za pomocą metod biblioteki pandas fillna() oraz max()

```
def fill_missing_max(df, work_columns):
    for col in work_columns:
        df[col] = df[col].fillna(df[col].max())
    return df
```

Przykład 4.4: Wypełnienie brakujących wartości maksimum

## 4.6 Wypełnienie brakujących wartości za pomocą regresji liniowej

W tym scenariuszu wykorzystano pozostałe rekordy, aby przy pomocy regresji liniowej wygenerować brakujące wartości

```
def fill_missing_regression(df, numeric):
    for col in numeric:
        df_num = df[numeric]
        test_data = df_num[df_num[col].isnull()]
        df_num = df_num.dropna()
        x_train = df_num.drop(col, axis=1)
        y_train = df_num[col]
        lr = LinearRegression()
        lr.fit(x_train, y_train)
        test_col = []
        for i in numeric:
            if(i != col):
                test_col.append(i)
        x_test = test_data[test_col]
        x_test = fill_missing_mean(x_test, test_col)
        y_pred = lr.predict(x_test)
        test_data[col] = y_pred
        for i in test_data.index.values:
            df.at[i, col] = test_data.loc[i][col]
    return df
```

Przykład 4.5: Wypełnienie brakujących wartości za pomocą regresji liniowej

## 4.7 Standaryzacja

Dzięki StandardScaler z biblioteki sklearn dokonano standaryzacji kolumn liczbowych

```

def standardize(df, work_columns):
    standard_scaler = preprocessing.StandardScaler()
    for col in work_columns:
        values = df[col].values
        df_scaled = standard_scaler.fit_transform(
            values.reshape(-1, 1))
        df_scaled = pd.DataFrame(df_scaled)
        df[col] = df_scaled
    return df

```

Przykład 4.6: Standaryzacja kolumn liczbowych

## 4.8 Standaryzacja oraz skalowanie do przedziału (0,1)

Dzięki StandardScaler z biblioteki sklearn dokonano standaryzacji wraz ze skalowaniem do przedziału (0,1) kolumn liczbowych

```

def normalize(df, work_columns):
    min_max_scaler = preprocessing.MinMaxScaler()
    for col in work_columns:
        values = df[col].values
        df_scaled = min_max_scaler.fit_transform(values.reshape(-1, 1))
        df_scaled = pd.DataFrame(df_scaled)
        df[col] = df_scaled
    return df

```

Przykład 4.7: Skalowanie do przedziału (0,1)

## 4.9 Skalowanie do przedziału (0,1) oraz usunięcie wartości odstających

Poza skalowaniem z poprzedniego scenariusza, wykorzystano algorytm LocalOutlierFactor do usunięcia wartości odstających

```

def remove_outliers_lof(df, work_columns):
    df_temp = df
    df_temp = df_temp.loc[:, work_columns]
    clf = LocalOutlierFactor(n_neighbors=2)
    clf.fit(df_temp)
    y_pred_outliers = clf.fit_predict(df_temp)
    df_temp['outlier'] = y_pred_outliers

    df_temp = df_temp.loc[df_temp['outlier'] == 1]
    df_temp.drop('outlier', axis=1, inplace=True)

```

```
df_temp = df_temp.reset_index(drop=True)
df = df[df.index.isin(df_temp.index)]
return df
```

Przykład 4.8: Usuwanie wartości odstających

## 4.10 Kodowanie wartości kategorycznych

Wykorzystano LabelEncoder z biblioteki sklearn do zakodowania wartości kategorycznych na liczbowe. W przypadku, kiedy dla danej kolumny brakowało wartości, rekord usuwano

```
def encode_categorical(df, work_columns):
    encoder = LabelEncoder()
    for col in work_columns:
        df[col] = encoder.fit_transform(df[col])
    return df
```

Przykład 4.9: Usuwanie wartości odstających

## 4.11 Kodowanie wartości kategorycznych oraz wypełnienie brakujących wartości średnią

Po wykonaniu kodowania z poprzedniego scenariusza, wypełniono brakujące wartości wartością średnią

## 4.12 Scenariusz indywidualnego podejścia do zbioru danych

### 4.12.1 League of Legends stats

Dla statystyk z gry League of Legends jedyną dodatkową operacją względem poprzednich scenariuszy było usunięcie kolumny z imieniem postaci, jako że nie wносиła ona konkretnych informacji, a głównie identyfikowała dany rekord

```
def custom_scenario(df, num):
    df_10 = df.copy()
    df_10 = fill_missing_mean(df_10, numeric)
    df_10 = remove_outliers_lof(df_10, numeric)
    df_10 = normalize(df_10, numeric)
    df_10 = drop_columns(df_10, ['Name'])
    df_10 = encode_categorical(df_10, to_be_encoded)
    y = df_10['Tier']
    df_10 = df_10.apply(pd.to_numeric)
```

```

X = df_10
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.1, random_state=42)
score(
    "LoL_Stats",
    num,
    "Custom_preprocessing",
    X_train, y_train, X_test, y_test)

```

Przykład 4.10: Indywidualny scenariusz dla zestawu danych LoL Stats

#### 4.12.2 Australian Rain Forecast

Dla Australian Rain Forecast rozbito datę na dzień miesiąca, miesiąc oraz rok, dzięki czemu w teorii możemy zaobserwować trendy dotyczące na przykład poszczególnych miesięcy na przestrzeni wielu lat

```

def custom_scenario(df, num):
    df_10 = df.copy()
    df_10 = fill_missing_mean(df_10, numeric)
    df_10 = remove_outliers_lof(df_10, numeric)
    df_10 = normalize(df_10, numeric)
    # Extract day, month and year from date
    df_10['Year'] = pd.DatetimeIndex(df_10['Date']).year
    df_10['Month'] = pd.DatetimeIndex(df_10['Date']).month
    df_10['Day'] = pd.DatetimeIndex(df_10['Date']).day
    df_10 = drop_columns(df_10, ['Date'])
    to_be_encoded = [
        'Location',
        'WindGustDir',
        'WindDir9am',
        'WindDir3pm',
        'RainToday',
        'Day',
        'Month',
        'Year']
    df_10 = encode_categorical(df_10, to_be_encoded)
    y = df_10['RainTomorrow']
    df_10 = df_10.apply(pd.to_numeric)
    X = df_10
    X_train, X_test, y_train, y_test = train_test_split(
        X, y, test_size=0.1, random_state=42)
    score(
        "Aus_weather", num, "Custom_preprocessing",
        X_train, y_train, X_test, y_test)

```

Przykład 4.11: Indywidualny scenariusz dla zestawu danych Aus Weather

### 4.12.3 Titanic Survival

Dla zestawu danych Titanic wyciągnięto informację o tytule, jakim posługiwał się dany pasażer, dzięki czemu uzyskaliśmy informację o grupie społecznej, do której należeli pasażerowie. Dokonano również zmiany informacji o kabiny, którą zajmował pasażer, znacznie cenniejszą informacją od konkretnej kabiny jest sektor, w którym ona się znajdowała, informacja ta została uzyskana poprzez ograniczenie kodu kabiny jedynie do pierwszego znaku, który określa sektor

```
def custom_scenario(df,num):
    df_10 = df.copy()
    df_10['Title'] = df_10['Name'].str.extract(
        '([A-Za-z]+)\.', expand=False)
    df_10['Title'] = df_10['Title'].fillna(
        df_10['Title'].mode().iloc[0])
    df_10['Title'] = df_10['Title'].replace([
        'Lady', 'Countess', 'Capt', 'Col', 'Don', 'Dr', \
        'Major', 'Rev', 'Sir', 'Jonkheer', 'Dona'], 'Rare')
    df_10['Title'] = df_10['Title'].replace('Mlle', 'Miss')
    df_10['Title'] = df_10['Title'].replace('Ms', 'Miss')
    df_10['Title'] = df_10['Title'].replace('Mme', 'Mrs')
    df_10 = df_10.drop(['Name', 'Ticket', 'PassengerId'], axis=1)
    df_10['Cabin'] = df_10['Cabin'].fillna('000')
    df_10['Cabin'] = df_10['Cabin'].str[:1]
    df_10 = fill_missing_mean(df_10, numeric)
    df_10 = df_10.fillna(df_10.mode().iloc[0])
    to_be_encoded = ["Sex", "Embarked", "Cabin", "Title"]
    df_10 = encode_categorical(df_10, to_be_encoded)
    y = df_10['Survived']
    df_10 = df_10.apply(pd.to_numeric)
    X = df_10
    X_train, X_test, y_train, y_test = train_test_split(
        X, y, test_size=0.1, random_state=42)
    score(
        "Titanic", num, "Custom_preprocessing",
        X_train, y_train, X_test, y_test)
    Przykład 4.12: Usuwanie wartości odstających
```



## Rozdział 5

# Wyniki Eksperymentów

W poniższym rozdziale przedstawiono wyniki eksperymentów dla każdego z klasyfikatorów, z podziałem na zbliżone do siebie scenariusze, jak i również średnie wyniki dla każdego ze zbiorów danych.

## 5.1 League of Legends stats


### 5.1.1 Wypełnienie brakujących wartości

Wariant	Scenariusz	Trafność xgBoost	Trafność Random Forest	Trafność k-najbliższych sąsiadów	Średnia trafność
LoL Stats 1	Brak przygotowania	0.900000	0.800000	0.825000	0.841667±0.001806
	Wypełnienie średnią	0.938776	0.775510	0.734694	0.816327±0.007775
	Wypełnienie minimum	0.938776	0.693878	0.714286	0.782313±0.012310
	Wypełnienie maksimum	0.938776	0.775510	0.673469	0.795918±0.011939
	Wypełnienie regresją	0.938776	0.755102	0.693878	0.795918±0.010829
LoL Stats 2	Brak przygotowania	0.925000	0.750000	0.825000	0.833333±0.005139
	Wypełnienie średnią	0.959184	0.755102	0.734694	0.816327±0.010273
	Wypełnienie minimum	0.959184	0.714286	0.673469	0.782313±0.015919
	Wypełnienie maksimum	0.959184	0.755102	0.673469	0.795918±0.014438
	Wypełnienie regresją	0.959184	0.775510	0.714286	0.816327±0.010829
LoL Stats 3	Brak przygotowania	0.900000	0.625000	0.650000	0.725000±0.015417
	Wypełnienie średnią	0.959184	0.734694	0.653061	0.782313±0.016752
	Wypełnienie minimum	0.918367	0.775510	0.693878	0.795918±0.008608
	Wypełnienie maksimum	0.918367	0.734694	0.653061	0.768707±0.012310
	Wypełnienie regresją	0.938776	0.755102	0.673469	0.789116±0.012310

Tablica 5.1: Trafność klasyfikatorów dla zbioru Lol Stats po scenariuszach związanych z wypełnianiem brakujących wartości



Trafność klasyfikatorów dla trzech wariantów wygenerowanych braków w zbiorze LoL Stats




Rysunek 5.1: Trafność klasyfikatorów dla trzech wariantów wygenerowanych braków w zbiorze LoL Stats po wypełnieniu brakujących wartości

## 5.1.2 Standaryzacja

Wariant	Scenariusz	Trafność xgBoost	Trafność Random Forest	Trafność k-najbliższych sąsiadów	Średnia trafność
Lol Stats 1	Brak przygotowania	0.900000	0.800000	0.825000	0.841667 0.001806
	Standaryzacja	0.938776	0.775510	0.755102	0.823129 0.006756
	Skalowanie do (0-1)	0.938776	0.775510	0.653061	0.789116 0.013698
	Skalowanie (0-1) i usuwanie odstających	0.911111	0.688889	0.688889	0.762963 0.010974
Lol Stats 2	Brak przygotowania	0.925000	0.750000	0.825000	0.833333 0.005139
	Standaryzacja	0.959184	0.755102	0.755102	0.823129 0.009255
	Skalowanie do (0-1)	0.959184	0.755102	0.693878	0.802721 0.012865
	Skalowanie (0-1) i usuwanie odstających	0.863636	0.659091	0.681818	0.734848 0.008379
Lol Stats 3	Brak przygotowania	0.900000	0.625000	0.650000	0.725000 0.015417
	Standaryzacja	0.959184	0.734694	0.693878	0.795918 0.013605
	Skalowanie do (0-1)	0.959184	0.734694	0.755102	0.816327 0.010273
	Skalowanie (0-1) i usuwanie odstających aaa	0.866667	0.488889	0.644444	0.666667 0.024033

Tablica 5.2: Trafność klasyfikatorów dla zbioru Lol Stats po scenariuszach związanych ze standaryzacją

Trafność klasyfikatorów dla trzech wariantów wygenerowanych braków w zbiorze LoL Stats




Rysunek 5.2: Trafność klasyfikatorów dla trzech wariantów wygenerowanych braków w zbiorze LoL Stats po scenariuszach związanych ze standaryzacją

## 5.1.3 Kodowanie

Wariant	Scenariusz	Trafność xgBoost	Trafność Random Forest	Trafność k-najbliższych sąsiadów	Średnia trafność
LoL Stats 1	Brak przygotowania	0.900	0.800000	0.825000	0.841667 0.001806
	Kodowanie wartości kategorycznych	1.000	0.925000	0.900000	0.941667 0.001806
	Kodowanie wartości kategorycznych i wypełnianie wartości brakujących średnią	1.000	0.897959	0.714286	0.870748 0.013976
LoL Stats 2	Brak przygotowania	0.925	0.750000	0.825000	0.833333 0.005139
	Kodowanie wartości kategorycznych	1.000	0.875000	0.825000	0.900000 0.005417
	Kodowanie wartości kategorycznych i wypełnianie wartości brakujących średnią	1.000	0.918367	0.734694	0.884354 0.012310
LoL Stats 3	Brak przygotowania	0.900	0.625000	0.650000	0.725000 0.015417
	Kodowanie wartości kategorycznych	1.000	0.725000	0.675000	0.800000 0.020417
	Kodowanie wartości kategorycznych i wypełnianie wartości brakujących średnią	1.000	0.897959	0.693878	0.863946 0.016197

Tablica 5.3: Trafność klasyfikatorów dla zbioru Lol Stats po scenariuszach związanych z kodowaniem

Trafność klasyfikatorów dla trzech wariantów wygenerowanych braków w zbiorze LoL Stats




Rysunek 5.3: Trafność klasyfikatorów dla trzech wariantów wygenerowanych braków w zbiorze LoL Stats po scenariuszach związanych ze kodowaniem

Wariant	Scenariusz	Trafność xgBoost	Trafność Random Forest	Trafność k-najbliższych sąsiadów	Średnia trafność
Lol Stats 1	Brak przygotowania	0.900	0.800000	0.825000	0.841667 0.001806
	Przygotowanie dostosowane do zbioru	1.000	0.795455	0.954545	0.916667 0.007691
Lol Stats 2	Brak przygotowania	0.925	0.750000	0.825000	0.833333 0.005139
	Przygotowanie dostosowane do zbioru	1.000	0.818182	0.931818	0.916667 0.005624
Lol Stats 3	Brak przygotowania	0.900	0.625000	0.650000	0.725000 0.015417
	Przygotowanie dostosowane do zbioru	1.000	0.790698	1.000000	0.930233 0.009735

Tablica 5.4: Trafność klasyfikatorów dla zbioru Lol Stats po indywidualnym podejściu do zbioru

## 5.1.4 Indywidualne podejście

Trafność klasyfikatorów dla trzech wariantów wygenerowanych braków w zbiorze LoL Stats



Rysunek 5.4: Trafność klasyfikatorów dla trzech wariantów wygenerowanych braków w zbiorze LoL Stats po indywidualnym podejściu dla zbiorów

## 5.2 Australian Rain Forecast


### 5.2.1 Wypełnienie brakujących wartości

Wariant	Scenariusz	Trafność xgBoost	Trafność Random Forest	Trafność k-najbliższych sąsiadów	Średnia trafność
Australian Weather 1	Brak przygotowania	0.855405	0.849324	0.836486	0.847072 0.000062
	Wypełnienie średnią	0.829787	0.820669	0.820669	0.823708 0.000018
	Wypełnienie minimum	0.834650	0.819453	0.815805	0.823303 0.000067
	Wypełnienie maksimum	0.834043	0.820669	0.813374	0.822695 0.000073
	Wypełnienie regresją	0.830395	0.820669	0.822492	0.824519 0.000018
Australian Weather 2	Brak przygotowania	0.851351	0.835811	0.847297	0.844820 0.000043
	Wypełnienie średnią	0.827356	0.819453	0.817021	0.821277 0.000019
	Wypełnienie minimum	0.837082	0.821277	0.822492	0.826950 0.000052
	Wypełnienie maksimum	0.834043	0.818845	0.817021	0.823303 0.000058
	Wypełnienie regresją	0.839514	0.821884	0.821277	0.827558 0.000072
Australian Weather 3	Brak przygotowania	0.842568	0.830405	0.829730	0.834234 0.000035
	Wypełnienie średnią	0.834043	0.820669	0.822492	0.825735 0.000035
	Wypełnienie minimum	0.841337	0.821277	0.818237	0.826950 0.000105
	Wypełnienie maksimum	0.829179	0.821277	0.820669	0.823708 0.000015
	Wypełnienie regresją	0.834650	0.820669	0.823100	0.826140 0.000037

Tablica 5.5: Trafność klasyfikatorów dla zbioru Australian Weather po scenariuszach związanych z wypełnianiem brakujących wartości



Trafność klasyfikatorów dla trzech wariantów wygenerowanych braków w zbiorze Australian Weather




Rysunek 5.5: Trafność klasyfikatorów dla trzech wariantów wygenerowanych braków w zbiorze Australian Weather po wypełnieniu brakujących wartości

## 5.2.2 Standaryzacja

Wariant	Scenariusz	Trafność xgBoost	Trafność Random Forest	Trafność k-najbliższych sąsiadów	Średnia trafność
Australian Weather 1	Brak przygotowania	0.855405	0.849324	0.836486	0.847072 0.000062
	Standaryzacja	0.829787	0.820669	0.824924	0.825127 0.000014
	Skalowanie do (0-1)	0.829787	0.820669	0.812766	0.821074 0.000048
	Skalowanie (0-1) i usuwanie odstających	0.838910	0.825279	0.825898	0.830029 0.000039
Australian Weather 2	Brak przygotowania	0.851351	0.835811	0.847297	0.844820 0.000043
	Standaryzacja	0.827356	0.819453	0.821277	0.822695 0.000011
	Skalowanie do (0-1)	0.827356	0.819453	0.812766	0.819858 0.000036
	Skalowanie (0-1) i usuwanie odstających	0.837871	0.829827	0.826114	0.831271 0.000024
Australian Weather 3	Brak przygotowania	0.842568	0.830405	0.829730	0.834234 0.000035
	Standaryzacja	0.834043	0.820669	0.823100	0.825937 0.000034
	Skalowanie do (0-1)	0.834043	0.820669	0.815198	0.823303 0.000063
	Skalowanie (0-1) i usuwanie odstających	0.848729	0.834470	0.830130	0.837776 0.000063

Tablica 5.6: Trafność klasyfikatorów dla zbioru Australian Weather po scenariuszach związanych ze standaryzacją

Trafność klasyfikatorów dla trzech wariantów wygenerowanych braków w zbiorze Australian Weather




Rysunek 5.6: Trafność klasyfikatorów dla trzech wariantów wygenerowanych braków w zbiorze Australian Weather po scenariuszach związanych ze standaryzacją

## 5.2.3 Kodowanie

Wariant	Scenariusz	Trafność xgBoost	Trafność Random Forest	Trafność k-najbliższych sąsiadów	Średnia trafność
Aus Weather 1	Brak przygotowania	0.855405	0.849324	0.836486	0.847072 0.000062
	Kodowanie wartości kategorycznych	1.000000	0.960811	0.847297	0.936036 0.004193
	Kodowanie wartości kategorycznych i wypełnianie wartości brakujących średnią	1.000000	0.944073	0.825532	0.923202 0.005291
Aus Weather 2	Brak przygotowania	0.851351	0.835811	0.847297	0.844820 0.000043
	Kodowanie wartości kategorycznych	1.000000	0.955405	0.846622	0.934009 0.004150
	Kodowanie wartości kategorycznych i wypełnianie wartości brakujących średnią	1.000000	0.941641	0.826748	0.922796 0.005180
Aus Weather 3	Brak przygotowania	0.842568	0.830405	0.829730	0.834234 0.000035
	Kodowanie wartości kategorycznych	1.000000	0.938514	0.833108	0.923874 0.004749
	Kodowanie wartości kategorycznych i wypełnianie wartości brakujących średnią	1.000000	0.943465	0.827964	0.923810 0.005126

Tablica 5.7: Trafność klasyfikatorów dla zbioru Australian Weather po scenariuszach związanych z kodowaniem

Trafność klasyfikatorów dla trzech wariantów wygenerowanych braków w zbiorze Australian Weather




Rysunek 5.7: Trafność klasyfikatorów dla trzech wariantów wygenerowanych braków w zbiorze Australian Weather po scenariuszach związanych ze kodowaniem

Wariant	Scenariusz	Trafność xgBoost	Trafność Random Forest	Trafność k-najbliższych sąsiadów	Średnia trafność
Australian Weather 1	Brak przygotowania	0.855405	0.849324	0.836486	0.847072 0.000062
	Przygotowanie dostosowane do zbioru	1.000000	0.984587	0.788533	0.924373 0.009266
Australian Weather 2	Brak przygotowania'	0.851351	0.835811	0.847297	0.844820 0.000043
	Przygotowanie dostosowane do zbioru	1.000000	0.983970	0.799630	0.927867 0.008265
Australian Weather 3	Brak przygotowania'	0.842568	0.830405	0.829730	0.834234 0.000035
	Przygotowanie dostosowane do zbioru	1.000000	0.981481	0.790741	0.924074 0.008946

Tablica 5.8: Trafność klasyfikatorów dla zbioru Aus Weather po indywidualnym podejściu do zbioru

## 5.2.4 Indywidualne podejście

Trafność klasyfikatorów dla trzech wariantów wygenerowanych braków w zbiorze Australian Weather



Rysunek 5.8: Trafność klasyfikatorów dla trzech wariantów wygenerowanych braków w zbiorze Australian Weather po indywidualnym podejściu dla zbiorów

### 5.3 Titanic Survival


#### 5.3.1 Wypełnienie brakujących wartości

Wariant	Scenariusz	Trafność xgBoost	Trafność Random Forest	Trafność k-najbliższych sąsiadów	Średnia trafność
Titanic 1	Brak przygotowania	0.777778	0.500000	0.722222	0.666667 0.014403
	Wypełnienie średnią	0.722222	0.744444	0.700000	0.722222 0.000329
	Wypełnienie minimum	0.733333	0.755556	0.688889	0.725926 0.000768
	Wypełnienie maksimum	0.755556	0.744444	0.688889	0.729630 0.000850
	Wypełnienie regresją	0.711111	0.733333	0.700000	0.714815 0.000192
Titanic 2	Brak przygotowania	0.684211	0.631579	0.578947	0.631579 0.001847
	Wypełnienie średnią	0.722222	0.733333	0.677778	0.711111 0.000576
	Wypełnienie minimum	0.722222	0.744444	0.677778	0.714815 0.000768
	Wypełnienie maksimum	0.777778	0.766667	0.677778	0.740741 0.002003
	Wypełnienie regresją	0.733333	0.733333	0.677778	0.714815 0.000686
Titanic 3	Brak przygotowania	0.631579	0.736842	0.578947	0.649123 0.004309
	Wypełnienie średnią	0.744444	0.744444	0.711111	0.733333 0.000247
	Wypełnienie minimum	0.744444	0.744444	0.688889	0.725926 0.000686
	Wypełnienie maksimum	0.722222	0.733333	0.700000	0.718519 0.000192
	Wypełnienie regresją	0.755556	0.722222	0.700000	0.725926 0.000521

Tablica 5.9: Trafność klasyfikatorów dla zbioru Titanic po scenariuszach związanych z wypełnianiem brakujących wartości



Trafność klasyfikatorów dla trzech wariantów wygenerowanych braków w zbiorze Titanic




Rysunek 5.9: Trafność klasyfikatorów dla trzech wariantów wygenerowanych braków w zbiorze Titanic po wypełnieniu brakujących wartości

## 5.3.2 Standaryzacja

Wariant	Scenariusz	Trafność xgBoost	Trafność Random Forest	Trafność k-najbliższych sąsiadów	Średnia trafność
Titanic 1	Brak przygotowania	0.777778	0.500000	0.722222	0.666667 0.014403
	Standaryzacja	0.722222	0.744444	0.644444	0.703704 0.001838
	Skalowanie do (0-1)	0.722222	0.744444	0.577778	0.681481 0.005460
	Skalowanie (0-1) i usuwanie odstających	0.703125	0.718750	0.656250	0.692708 0.000705
Titanic 2	Brak przygotowania	0.684211	0.631579	0.578947	0.631579 0.001847
	Standaryzacja	0.722222	0.733333	0.633333	0.696296 0.002003
	Skalowanie do (0-1)	0.722222	0.733333	0.577778	0.677778 0.005021
	Skalowanie (0-1) i usuwanie odstających	0.718750	0.718750	0.656250	0.697917 0.000868
Titanic 3	Brak przygotowania	0.631579	0.736842	0.578947	0.649123 0.004309
	Standaryzacja	0.744444	0.744444	0.644444	0.711111 0.002222
	Skalowanie do (0-1)	0.744444	0.744444	0.577778	0.688889 0.006173
	Skalowanie (0-1) i usuwanie odstających	0.646154	0.630769	0.692308	0.656410 0.000684

Tablica 5.10: Trafność klasyfikatorów dla zbioru Titanic po scenariuszach związanych ze standaryzacją

Trafność klasyfikatorów dla trzech wariantów wygenerowanych braków w zbiorze Titanic




Rysunek 5.10: Trafność klasyfikatorów dla trzech wariantów wygenerowanych braków w zbiorze Titanic po scenariuszach związanych ze standaryzacją

## 5.3.3 Kodowanie

Wariant	Scenariusz	Trafność xgBoost	Trafność Random Forest	Trafność k-najbliższych sąsiadów	Średnia trafność
Titanic 1	Brak przygotowania	0.777778	0.500000	0.722222	0.666667 0.014403
	Kodowanie wartości kategorycznych	1.000000	1.000000	0.611111	0.870370 0.033608
	Kodowanie wartości kategorycznych i wypełnianie wartości brakujących średnią	1.000000	1.000000	0.700000	0.900000 0.020000
Titanic 2	Brak przygotowania	0.684211	0.684211	0.578947	0.578947 0.001847
	Kodowanie wartości kategorycznych	1.000000	1.000000	0.578947	0.859649 0.039397
	Kodowanie wartości kategorycznych i wypełnianie wartości brakujących średnią	1.000000	1.000000	0.677778	0.892593 0.023073
Titanic 3	Brak przygotowania	0.631579	0.736842	0.578947	0.649123 0.004309
	Kodowanie wartości kategorycznych	1.000000	1.000000	0.578947	0.859649 0.039397
	Kodowanie wartości kategorycznych i wypełnianie wartości brakujących średnią	1.000000	1.000000	0.700000	0.900000 0.020000

Tablica 5.11: Trafność klasyfikatorów dla zbioru Titanic po scenariuszach związanych z kodowaniem

Trafność klasyfikatorów dla trzech wariantów wygenerowanych braków w zbiorze Titanic




Rysunek 5.11: Trafność klasyfikatorów dla trzech wariantów wygenerowanych braków w zbiorze Titanic po scenariuszach związanych ze kodowaniem

## 5.3.4 Indywidualne podejście

Wariant	Scenariusz	Trafność xgBoost	Trafność Random Forest	Trafność k-najbliższych sąsiadów	Średnia trafność
Titanic 1	Brak przygotowania	0.777778	0.500000	0.722222	0.666667 0.014403
	Przygotowanie dostosowane do zbioru	1.000000	1.000000	0.833333	0.944444 0.006173
Titanic 2	Brak przygotowania	0.684211	0.631579	0.578947	0.631579 0.001847
	Przygotowanie dostosowane do zbioru	1.000000	1.000000	0.811111	0.937037 0.007929
Titanic 3	Brak przygotowania	0.631579	0.736842	0.578947	0.649123 0.004309
	Przygotowanie dostosowane do zbioru	1.000000	1.000000	0.822222	0.940741 0.007023

Tablica 5.12: Trafność klasyfikatorów dla zbioru Titanic po indywidualnym podejściu do zbioru


Trafność klasyfikatorów dla trzech wariantów wygenerowanych braków w zbiorze Titanic



Rysunek 5.12: Trafność klasyfikatorów dla trzech wariantów wygenerowanych braków w zbiorze Titanic po indywidualnym podejściu dla zbiorów

## 5.4 Średnie wyniki


### 5.4.1 Wypełnienie brakujących wartości



Rysunek 5.13: Średnia trafność klasyfikatorów dla zbioru danych Lol Stats dla grupy scenariuszy wypełniania brakujących wartości




Średnia trafność klasyfikatorów dla poszczególnych scenariuszy zbioru danych Titanic 1



Rysunek 5.14: Średnia trafność klasyfikatorów dla zbioru danych Titanic dla grupy scenariuszy wypełniania brakujących wartości


Średnia trafność klasyfikatorów dla poszczególnych scenariuszy zbioru danych Aus Weather



Rysunek 5.15: Średnia trafność klasyfikatorów dla zbioru danych Australian Weather dla grupy scenariuszy wypełniania brakujących wartości


Dla Lol Stats oraz Australian Weather średnia trafność nieznacznie maleje po wypełnieniu brakujących wartości (Rysunek 5.37, Rysunek 5.39). Dla zbioru Titanic w każdym przypadku po wypełnieniu brakujących wartości średnia trafność klasyfikacji wzrosła (Rysunek 5.38)

## 5.4.2 Standaryzacja




Rysunek 5.16: Średnia trafność klasyfikatorów dla zbioru danych Lol Stats dla standaryzacji

Średnia trafność klasyfikatorów dla poszczególnych scenariuszy zbioru danych Titanic 1



Rysunek 5.17: Średnia trafność klasyfikatorów dla zbioru danych Titanic dla standaryzacji

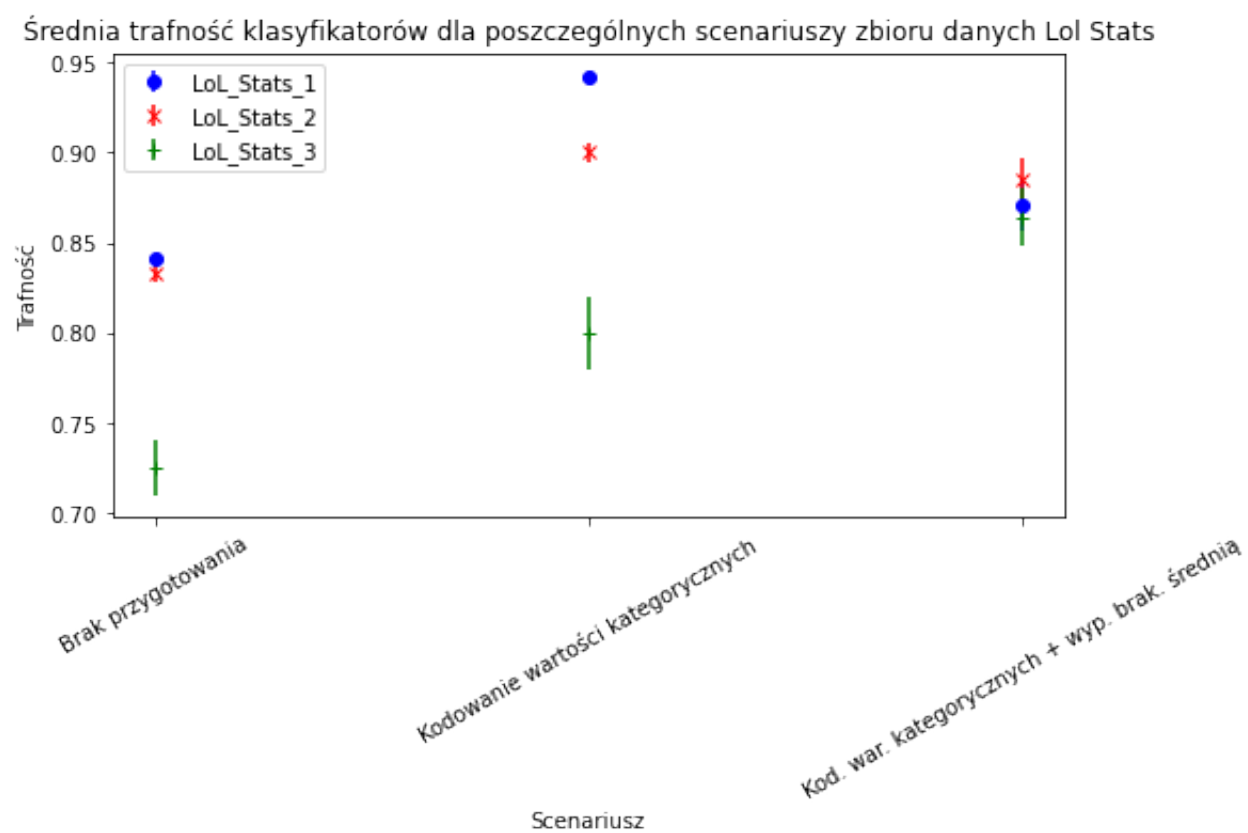
Średnia trafność klasyfikatorów dla poszczególnych scenariuszy zbioru danych Aus Weather



Rysunek 5.18: Średnia trafność klasyfikatorów dla zbioru danych Australian Weather dla standaryzacji


W kwestii Standaryzacji dla zestawu danych Lol Stats najlepszy wynik uzyskujemy dla Standaryzacji oraz Standaryzacji do przedziału (0,1) (Rysunek 5.40), dla Titanic Standaryzacji (Rysunek 5.41), a dla Australian Rain Forecast dla braku przygotowania (Rysunek 5.42)

## 5.4.3 Kodowanie




Rysunek 5.19: Średnia trafność klasyfikatorów dla zbioru danych Lol Stats dla kodowania

Średnia trafność klasyfikatorów dla poszczególnych scenariuszy zbioru danych Titanic 1



Rysunek 5.20: Średnia trafność klasyfikatorów dla zbioru danych Titanic dla kodowania

Średnia trafność klasyfikatorów dla poszczególnych scenariuszy zbioru danych Aus Weather



Rysunek 5.21: Średnia trafność klasyfikatorów dla zbioru danych Australian Weather dla kodowania

Dla każdego zestawu danych Standaryzacja daje poprawę średniej trafności klasyfikacji, istnieją jednak pewne różnice pomiędzy samym kodowaniem, a kodowaniem z wypełnianiem brakujących wartości. Dla zbioru Lol Stats samo kodowanie powoduje dość rozbieżne wyniki pomiędzy trzema przypadkami wygenerowanych braków, jednak kodowanie z wypełnianiem daje w miarę spójny obraz średniej trafności (Rysunek 5.43), dla Titanic wypełnianie nieznacznie zwiększa średnią trafność klasyfikacji (Rysunek 5.44), natomiast dla Australian Weather najlepszy wynik uzyskujemy dla kodowania bez wypełniania brakujących wartości (Rysunek 5.45)

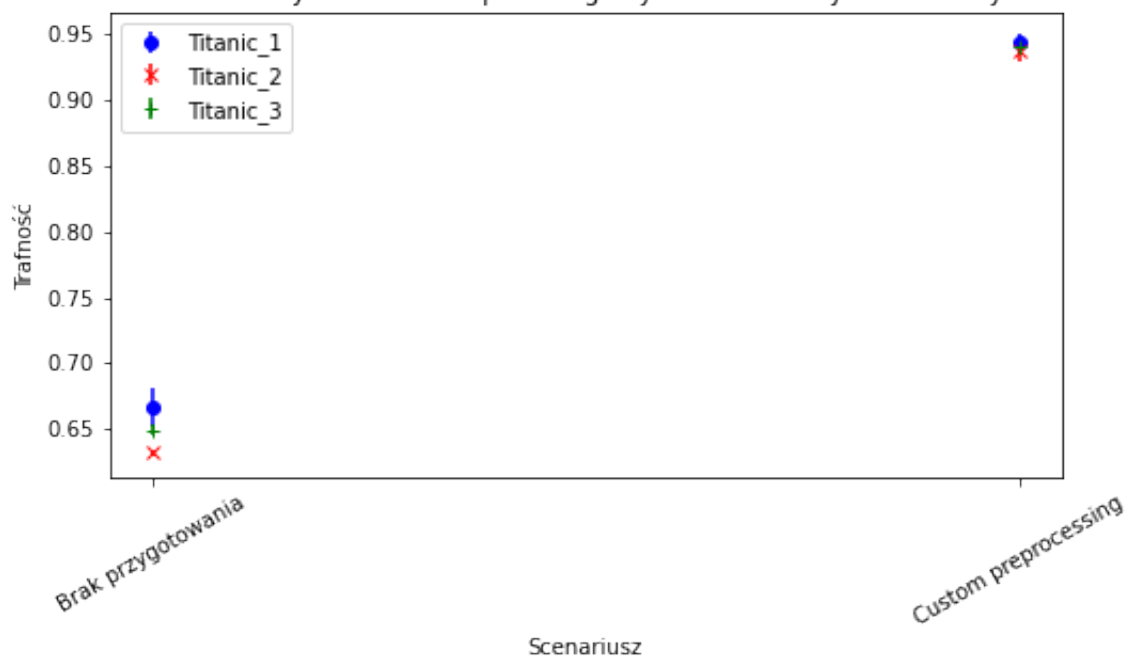


## 5.4.4 Indywidualne podejście




Rysunek 5.22: Średnia trafność klasyfikatorów dla zbioru danych Lol Stats dla indywidualnego podejścia dla zbioru

Średnia trafność klasyfikatorów dla poszczególnych scenariuszy zbioru danych Titanic 1



Rysunek 5.23: Średnia trafność klasyfikatorów dla zbioru danych Titanic dla indywidualnego podejścia dla zbioru

Średnia trafność klasyfikatorów dla poszczególnych scenariuszy zbioru danych Aus Weather



Rysunek 5.24: Średnia trafność klasyfikatorów dla zbioru danych Australian Weather dla indywidualnego podejścia dla zbioru

Dla każdego z trzech zbiorów danych podejścia oparte na indywidualnym podejściu do zbioru danych dają wymierną poprawę średniej trafności (Rysunek 5.48, Rysunek 5.47, Rysunek 5.46)



## Rozdział 6

# Podsumowanie

W poniższym rozdziale przedstawiono, jak wyniki eksperymentów mają się do założeń postawionych przed ich przeprowadzeniem, oraz zapisano wnioski na podstawie wyników.

### 6.1 Konieczność przygotowania danych

Wariant	Trafność xgBoost	Trafność Random Forest	Trafność k-najbliższych sąsiadów
Titanic 1	0.777778	0.500000	0.722222
Titanic 2	0.684211	0.631579	0.578947
Titanic 3	0.631579	0.736842	0.578947
Lol Stats 1	0.900000	0.80000	0.825000
Lol Stats 2	0.925000	0.750000	0.825000
Lol Stats 3	0.900000	0.625000	0.650000
Aus Weather 1	0.855405	0.849324	0.836486
Aus Weather 2	0.851351	0.835811	0.847297
Aus Weather 3	0.842568	0.830405	0.829730

Tablica 6.1: Trafność klasyfikatorów bez przygotowania danych

W zależności od tego, jaki klasyfikator wybierzemy, bez przygotowania danych możemy uzyskać wyniki zarówno porównywalne z losowym wyborem klasy, ale i takie, które w wielu przypadkach mogłyby być uznać za zadowalające (Tablica 6.1). Równocześnie musimy pamiętać, że w dziedzinach takich jak medycyna, czy bankowość chcielibyśmy, aby wytrenowane klasyfikatory były jak najbliższe perfekcji. Z tego powodu cenną informacją jest to, jak bardzo możemy poprawić trafność klasyfikatorów dzięki przygotowaniu danych.

## 6.2 Wpływ źle dobranych sposobów przygotowania danych

Wariant	Scenariusz	Trafność xgBoost	Trafność Random Forest	Trafność k-najbliższych sąsiadów
Titanic 1	Brak przygotowania	0.777778	0.500000	0.722222
	Skalowanie do (0-1)	0.722222	0.744444	0.577778
Lol Stats 1	Brak przygotowania	0.900000	0.800000	0.825000
	Wypełnienie minimum	0.938776	0.693878	0.714286
	Skalowanie (0-1) i usuwanie odstających	0.911111	0.688889	0.688889
Aus Weather 2	Brak przygotowania	0.851351	0.835811	0.847297
	Wypełnienie maksimum	0.834043	0.818845	0.817021
	Skalowanie do (0-1)	0.827356	0.819453	0.812766

Tablica 6.2: Przypadki, w których przygotowanie danych wpłynęło negatywnie na trafność

Zgodnie z hipotezą, przygotowanie danych w każdym przypadku powinno skutkować lepszymi rezultatami klasyfikacji, jednak podczas eksperymentów zauważono przypadki, w których przygotowanie danych pogorszyło jakość klasyfikacji (Tablica 6.2). Jednoznacznie pokazuje to, że przeprowadzenie przygotowania danych bez przeanalizowania zbioru i dobrania odpowiednich metod do danego przypadku, może skutkować pogorszeniem skuteczności klasyfikacji.

### 6.3 Najlepsze wyniki po przygotowaniu danych

Wariant	Scenariusz	Trafność xgBoost	Trafność Random Forest	Trafność k-najbliższych sąsiadów
Titanic 1	Brak przygotowania	0.777778	0.500000	0.722222
	Kodowanie wartości kategorycznych i wypełnianie wartości brakujących średnią	1.000000	1.000000	0.700000
	Przygotowanie dostosowane do zbioru	1.000000	1.000000	0.833333
Titanic 2	Brak przygotowania	0.684211	0.631579	0.578947
	Kodowanie wartości kategorycznych i wypełnianie wartości brakujących średnią	1.000000	1.000000	0.677778
	Przygotowanie dostosowane do zbioru	1.000000	1.000000	0.811111
Titanic 3	Brak przygotowania	0.631579	0.736842	0.578947
	Kodowanie wartości kategorycznych i wypełnianie wartości brakujących średnią	1.000000	1.000000	0.700000
	Przygotowanie dostosowane do zbioru	1.000000	1.000000	0.822222

Tablica 6.3: Scenariusze dla zbioru Titanic, w których przygotowanie danych wpłynęło najlepiej na trafność

Dla zbioru Titanic po przygotowaniu dwa klasyfikatory osiągają 100% trafności, natomiast w przypadku trzeciego możemy zauważyć znaczną poprawę trafności (Tablica 6.3). Przed przygotowaniem w poszczególnych przypadkach można było zauważyć, że klasyfikator radzi sobie niewiele lepiej niż dobierając klasyfikację losowo (50%), natomiast po przygotowaniu dostosowanym do danego zbioru, trafność klasyfikacji jest wysoka (80%), bądź nawet perfekcyjna (100%).

Wariant	Scenariusz	Trafność xgBoost	Trafność Random Forest	Trafność k-najbliższych sąsiadów
Lol Stats 1	Brak przygotowania	0.900	0.800000	0.825000
	Kodowanie wartości kategorycznych	1.000	0.925000	0.900000
	Przygotowanie dostosowane do zbioru	1.000	0.795455	0.954545
Lol Stats 2	Brak przygotowania	0.925	0.750000	0.825000
	Kodowanie wartości kategorycznych	1.000	0.875000	0.825000
	Kodowanie wartości kategorycznych i wypełnianie wartości brakujących średnią	1.000	0.918367	0.734694
	Przygotowanie dostosowane do zbioru	1.000	0.818182	0.931818
Lol Stats 3	Brak przygotowania	0.900	0.625000	0.650000
	Kodowanie wartości kategorycznych i wypełnianie wartości brakujących średnią	1.000	0.897959	0.693878
	Przygotowanie dostosowane do zbioru	1.000	0.790698	1.000000

Tablica 6.4: Scenariusze dla zbioru Lol Stats, w których przygotowanie danych wpłynęło najlepiej na trafność

Powyżej przedstawiono najlepsze wyniki klasyfikacji dla zbioru Lol Stats (Tablica 6.4) Dla klasyfikatora Random Forest najlepsze wyniki uzyskano przy kodowaniu wartości kategorycznych (około 90%), dla xgBoost zarówno kodowanie jak i indywidualne przygotowanie skutkują idealną klasyfikacją. Dla k-najbliższych sąsiadów najlepsze wyniki uzyskano przy indywidualnym podejściu do zbioru (powyżej 90%) ===== TO BE AMENDED =====



Wariant	Scenariusz	Trafność xgBoost	Trafność Random Forest	Trafność k-najbliższych sąsiadów
Aus Weather 1	Brak przygotowania	0.855405	0.849324	0.836486
	Kodowanie wartości kategoriycznych	1.000000	0.960811	0.847297
	Przygotowanie dostosowane do zbioru	1.000000	0.984587	0.788533
Aus Weather 2	Brak przygotowania	0.851351	0.835811	0.847297
	Kodowanie wartości kategoriycznych	1.000000	0.955405	0.846622
	Kodowanie wartości kategoriycznych i wypełnianie wartości brakujących średnią	1.000000	0.941641	0.826748
	Przygotowanie dostosowane do zbioru	1.000000	0.983970	0.799630
Aus Weather 3	Brak przygotowania	0.842568	0.830405	0.829730
	Kodowanie wartości kategoriycznych	1.000000	0.938514	0.833108
	Kodowanie wartości kategoriycznych i wypełnianie wartości brakujących średnią	1.000000	0.943465	0.827964
	Przygotowanie dostosowane do zbioru	1.000000	0.981481	0.790741

Tablica 6.5: Scenariusze dla zbioru Australian Weather, w których przygotowanie danych wpłynęło najlepiej na trafność

Częścią przygotowania dostosowanego do zbioru Australian Weather, było rozbięcie kolumny z datą na trzy kolumny, zawierające dzień, miesiąc oraz rok, co skutkowało pogorszeniem trafności klasyfikacji dla k-najbliższych sąsiadów (Tablica 6.5). Dla pozostałych klasyfikatorów przygotowanie dostosowane do zbioru pozwoliło uzyskać najlepszy, bądź jeden z najlepszych wyników. Należy zwrócić uwagę na fakt, że różnice w trafności między scenariuszami bez oraz z przygotowaniem danych, nie były tak znaczne jak dla pozostałych zbiorów.

Tabela z przykładami

## 6.4 Potencjalne dalsze kierunki badań

Z wyników eksperymentów wynika korelacja między wielkością zbioru, a znaczeniem przygotowania danych. Przy niewielkich zbiorach dzięki przygotowaniu danych jesteśmy w stanie uzyskać znacznie lepsze wyniki. Natomiast przy większym zbiorze uzupełnianie braków może prowadzić do przekłamań, a co za tym

idzie mniejszej skuteczności klasyfikatora (Tablica 6.2). Stąd zasadnym były by dalsze badania, prowadzone pod kątem zależności między wielkością zbioru, a znaczeniem przygotowania danych.

## 6.5 Najlepsze praktyki przygotowania danych

Z przeprowadzonych eksperymentów wynika, że odpowiednie przygotowanie danych zwiększa w umiarkowanym stopniu celność klasyfikatorów. Jeżeli przed analizą danych dogłębnie poznamy i zrozumiemy zbiór danych, będziemy mogli wybrać najbardziej odpowiednie metody przygotowania danych dla danego zbioru, a co za tym idzie wyniki analizy będą najbardziej trafne. Należy jednak zwrócić uwagę, że nie wszystkie scenariusze skutkowały jednoznaczną poprawą rezultatów, dlatego dobrą praktyką jest wielokrotne przygotowywanie danych na różne sposoby tak, aby znaleźć taki, który zwraca najlepsze rezultaty. Na szczególne wyróżnienie zasługuje kodowanie wartości kategoriycznych na liczbowe, gdyż w każdym przypadku zastosowanie tej metody znacznie zwiększyło trafność klasyfikacji.

# Bibliografia

- [1] Zbiór danych Titanic dostępny do pobrania ze strony kaggle.com
- [2] Zbiór danych Lol Stats dostępny do pobrania ze strony kaggle.com
- [3] Zbiór danych Australian Rain dostępny do pobrania ze strony kaggle.com
- [4] "Transforming Unstructured Data into Useful Information", *Big Data, Mining, and Analytics*, Auerbach Publications, pp. 227–246, 2014-03-12, doi:10.1201/b16666-14, ISBN 978-0-429-09529-0
- [5] MOIS, George; FOLEA, Silviu; SANISLAV, Teodora. Analysis of three IoT-based wireless sensors for environmental monitoring. *IEEE Transactions on Instrumentation and Measurement*, 2017, 66.8: 2056-2064.
- [6] Margo, Robert A. (2000). *Wages and labor markets in the United States, 1820-1860*. University of Chicago Press. ISBN 0-226-50507-3. OCLC 41285104
- [7] Marshall, G. (2005). The purpose, design and administration of a questionnaire for data collection. *Radiography*, 11(2), 131-136.
- [8] Fabijan, A., Olsson, H. H., Bosch, J. (2015). Customer feedback and data collection techniques in software R&D: a literature review. In *Software Business: 6th International Conference, ICSOB 2015, Braga, Portugal, June 10-12, 2015, Proceedings 6* (pp. 139-153). Springer International Publishing.
- [9] Hasan, M. K., Alam, M. A., Roy, S., Dutta, A., Jawad, M. T., Das, S. (2021). Missing value imputation affects the performance of machine learning: A review and analysis of the literature (2010–2021). *Informatics in Medicine Unlocked*, 27, 100799.
- [10] E. Kreyszig (1979). *Advanced Engineering Mathematics* (4th ed.). Wiley. p. 880, eq. 5. ISBN 0-471-02140-7.
- [11] Okada, S., Ohzeki, M., Taguchi, S. (2019). Efficient partition of integer optimization problems with one-hot encoding. *Scientific reports*, 9(1), 13036.
- [12] Wang, H., Bah, M. J., Hammad, M. (2019). Progress in outlier detection techniques: A survey. *Ieee Access*, 7, 107964-108000.

- [13] Alghushairy, O., Alsini, R., Soule, T., Ma, X. (2020). A review of local outlier factor algorithms for outlier detection in big data streams. *Big Data and Cognitive Computing*, 5(1), 1.
- [14] Potdar, K., Pardawala, T. S., Pai, C. D. (2017). A comparative study of categorical variable encoding techniques for neural network classifiers. *International journal of computer applications*, 175(4), 7-9.
- [15] Narudin, F. A., Feizollah, A., Anuar, N. B., Gani, A. (2016). Evaluation of machine learning classifiers for mobile malware detection. *Soft Computing*, 20, 343-357.
- [16] Khanal, S. S., Prasad, P. W. C., Alsadoon, A., Maag, A. (2020). A systematic review: machine learning based recommendation systems for e-learning. *Education and Information Technologies*, 25, 2635-2664.
- [17] Ezugwu, A. E., Ikotun, A. M., Oyelade, O. O., Abualigah, L., Agushaka, J. O., Eke, C. I., Akinyelu, A. A. (2022). A comprehensive survey of clustering algorithms: State-of-the-art machine learning applications, taxonomy, challenges, and future research prospects. *Engineering Applications of Artificial Intelligence*, 110, 104743.
- [18] Sousa, M. J., Pesqueira, A. M., Lemos, C., Sousa, M., & Rocha, Á. (2019). Decision-making based on big data analytics for people management in healthcare organizations. *Journal of medical systems*, 43, 1-10.
- [19] Schildkamp, K., Lai, M. K., & Earl, L. (Eds.). (2012). *Data-based decision making in education: Challenges and opportunities*.
- [20] Fávero, L. P., & Belfiore, P. (2019). *Data science for business and decision making*. Academic Press.
- [21] Definicja dostępna w dokumentacji biblioteki XGBoost
- [22] Cover, Thomas M.; Hart, Peter E. (1967). "Nearest neighbor pattern classification"(PDF). *IEEE Transactions on Information Theory*. 13 (1): 21–27. CiteSeerX 10.1.1.68.2616. doi:10.1109/TIT.1967.1053964.
- [23] Ho, Tin Kam (1995). *Random Decision Forests* (PDF). *Proceedings of the 3rd International Conference on Document Analysis and Recognition*, Montreal, QC, 14–16 August 1995. pp. 278–282.
- [24] Artykuł na temat jakości danych na stronie firmy IBM